软件工程统计方法

随机变量及其分布(二)

陈振宇

南京大学软件学院

Email:zychen@software.nju.edu.cn

Homepage:software.nju.edu.cn/zychen





全 屏

返 回


内容提纲

- □统计学导论
- □描述统计
- □概率计算基础
- □随机变量及其分布
- □统计量及其抽样分布
- □参数估计
- □参数假设检验
- □非参数假设检验
- □方差分析
- □回归分析



本节内容 连续随机变量 数字特征 均匀分布 指数分布

正态分布



全 屏

1 本节内容

- □随机变量
- □分布函数
- ■数学期望
- □方差
- □常用分布
- □二维随机向量



本节内容连续随机证券等分分布数分布



第3页共100页

返 回

全 屏

2 连续随机变量

Example 1 一个靶子是半径为2米的圆盘,设击中靶上任意同心圆盘上的点的概率与该圆盘的面积成正比,并设射击都能击中靶,以X表示弹着点于圆心的距离. 试求随机变量X的分布函数.

解: 若X < 0, 则 $\{X \le x\}$ 是不可能事件, 于是 $F(x) = P\{X \le x\} = 0$. 若 $0 \le x \le 2$, 由题意, $P\{0 \le X \le x\} = kx^2$, k是某一常数, 为确定k的值, 取x = 2, 有 $P\{0 \le X \le 2\} = 2^2k$, 但已知 $P\{0 \le X \le 2\} = 1$, 故得k = 1/4, 即 $P\{0 \le X \le x\} = x^2/4$, 于是

$$F(x) = P\{X \le x\} = P\{X < 0\} + P\{0 \le X \le x\} = x^2/4$$

若X > 2, 由题意, 有 $F(x) = P\{X \le x\} = 1$. 综合上述, 即得X的分布函数为

$$F(x) = \begin{cases} 0, & x < 0\\ \frac{x^2}{4}, & 0 \le x < 2\\ 1, & x \ge 2 \end{cases}$$

X的分布函数也可以表示为

$$F(x) = \int_{-\infty}^{x} f(t)dt$$

其中f(t) = t/2, 0 < t < 2; f(t) = 0, 其他.



本 节 内 容 连 续 转 执 征 续 特 征 切 匀 分 布 布 布 布 布 布





第4页共100页


返 回

全 屏

连续随机变量

连续型随机变量及其密度函数的定义:

Definition 1 (概率密度) 对于随机变量X, 其分布函数为F(x), 如存在非负可积函数f(x), 使得对于任意实数x, 有 $F(x) = \int_{-\infty}^{x} f(t)dt$, 则称X为连续型随机变量, f(x)称为X的概率密度函数.





本节体。



第5页共100页

返回

全 屏

连续随机变量

概率密度函数的性质:

- 1. $f(x) \ge 0$;
- $2. \int_{-\infty}^{+\infty} f(x) dx = 1;$
- 3. 对于任意实数a,b(a < b),都有 $P(a < X \le b) = \int_a^b f(x) dx = F(b) F(a)$;
- 4. F 若 f(x) 在点x 处连续,则有 F'(x) = f(x),即分布函数 F(x) 是概率密度的一个原函数.
- 5. 对于连续性随机变量X, X取任一指定实数值a的概率均为0, 即 $P\{X=a\}=0$.



本节内容。连续字特征。





返 回

全 屏

例子

Example 2 设随机变量X具有概率密度

$$f(x) = \begin{cases} kx, & 0 \le x < 3\\ 2 - \frac{x}{2}, & 3 \le x \le 4\\ 0, & \cancel{4}$$

(1)确定常数k; (2)求X的分布函数F(x); (3)求 $P\{1 < X \leq \frac{7}{2}\}$.

解: (1)由 $\int_{-\infty}^{+\infty} f(x)dx = 1$ 得

$$\int_0^3 kx dx + \int_3^4 (2 - \frac{x}{2}) dx = 1$$

解得 $k = \frac{1}{6}$.

(2) 所以分布函数为

$$F(x) = \begin{cases} 0, & x < 0\\ \int_0^x \frac{t}{6} dt, & 0 \le x < 3\\ \int_0^3 \frac{t}{6} dt + \int_3^x 2 - \frac{t}{2} dt, & 3 \le x < 4\\ 1, & x \ge 4 \end{cases}$$

$$(3)P\{1 < X \le 7/2\} = F(7/2) - F(1) = \frac{41}{48}.$$







第7页共100页

返 回

全 屏

连续随机变量数学期望

设连续型随机变量X的概率密度为f(x),如果广义积分 $\int_{-\infty}^{+\infty}xf(x)dx$ 绝对收敛,则称此积分值为随机变量X的数学期望,记作E(X)或EX,即 $E(X)=\int_{-\infty}^{+\infty}xf(x)dx$.

如果上述级数或积分不绝对收敛, 则称此随机变量的数学期望不存在. **Theorem 1** 设Y=g(X)是随机变量X的函数, g是连续函数. 若X为具有密度函数f(x)的连续型随机变量, $\int_{-\infty}^{+\infty}g(x)f(x)dx$ 绝对收敛, 则

$$E(Y) = E(g(X)) = \int_{-\infty}^{+\infty} g(x)f(x)dx$$



本节内容 连续随机变量 数字特征 均匀分布 指数分布 正态分布





第8页共100页

返 回

全 屏

数学期望是一种最基本的数字特征。在物理学中, 矩是用于物体形状识别的重要参数指标。数学中矩的概念来自于物理学。在统计学中, 矩用来描述随机变量的数字特征。常用的矩有原点矩, 中心矩, 混合矩, 混合中心矩。

Definition 2 (**矩**, **Moment**) 设X,Y为两个随机变量, 不同矩的定义如下。

- 1. 若 $E(X^k)$ 存在 $(k=1,2,\cdots)$,称 $E(X^k)$ 为X的k阶原点矩或k阶矩,记为 μ_k 。
- 2. 若 $E((X EX)^k)$ 存在($k = 1, 2, \cdots$),称 $E((X EX)^k)$ 为X的k阶中点 矩,记为 v_k 。
- 3. 若 $E(X^kY^l)$ 存在 $(k,l=1,2,\cdots)$,则 $E(X^kY^l)$ 称为X,Y的k+l混合矩。
- 4. 若 $E((X E(X))^k (Y E(Y))^l)$ 存 在 $(k,l) = 1,2,\cdots)$,则 $E((X E(X))^k (Y E(Y))^l)$ 称为X,Y的k+l混合中心矩。



本节内容
连续等特征
均匀分布
指数分布





第 9 页 共 100 页

返 回

全 屏



Theorem 2 (中心矩的原点矩表示定理)

$$v_k = \sum_{i=0}^k C_k^i \mu_i (-\mu_1)^{k-i}$$
 (1)

根据中心矩的原点矩表示定理,前面四个k阶中心矩可以由原点矩表示如下:

$$v_1 = 0$$

$$v_2 = \mu_2 - \mu_1^2$$

$$v_3 = \mu_3 - 3\mu_2\mu_1 + 2\mu_1^3$$

$$v_4 = \mu_4 - 4\mu_3\mu_1 + 6\mu_2\mu_1^2 - 3\mu_1^4$$



本节内容连续陷机变量数字特征均分布





返 回

全 屏

我们介绍两外两个常用的矩:偏度和峰度。

Definition 3 (偏度, Skewness) 若随机变量X的三阶距存在,则

$$\gamma_1 = \frac{\upsilon_3}{\upsilon_2^{(\frac{3}{2})}} \tag{2}$$

称为X的偏度, 或偏度系数, 其中 v_2, v_3 分别为二阶和三阶中心矩。

偏度 γ_1 是一个描述分布对称程度的特征量。当偏度 $\gamma_1 = 0$ 时, 概率密度呈对称分布(注意不一定是以x = 0对称)。当偏度 $\gamma_1 < 0$ 时, 概率分布的左尾偏长, 称为负偏或左偏。当偏度 $\gamma_1 > 0$ 时, 概率分布的右尾偏长, 称为正偏或右偏。由于标准正态分布的三阶中心矩为0, 所以它的偏度为0。



本节内容连续为行机变量数分分布



关 闭

全 屏

Definition 4 (**峰度**, Kurtosis) 若随机变量X的三阶距存在, 则

$$\gamma_2 = \frac{v_4}{v_2^2} \tag{3}$$

称为X的峰度, 或峰度系数, 其中 v_2 , v_4 分别为二阶和四阶中心矩。

峰度 γ_2 是一个描述分布尖锐程度(或平坦程度)的特征量。峰度 γ_2 越大,表示概率分布越尖锐,反之越平坦均匀。由于标准正态分布的四阶中心矩为3,二阶中心矩为1,所以它的峰度为3。当 $\gamma_2=3$,说明随机变量的尖锐程度跟标准正态分布相当。当 $\gamma_2<3$,我们称之为低峰度,说明随机变量的分布比标准正态分布平坦。当 $\gamma_2>3$,我们称之为高峰度,说明随机变量的分布比标准正态分布尖锐。有些文献为了方便跟标准正态分布比较,将峰度的定义改为3中的比值减去3。



本 节内容 连续对机变量 数字特征 均匀分布 指数分布 正态分布



第 12页共 100页

返回

全 屏

连续随机变量的概率密度函数的 $[-\infty,\infty]$ 积分为1, 即累积面积为1。在统计推断中, 我们经常用到一个数字 x_p , 使得在 x_p 左边或右边的面积为p(0 。这种数字特征我们成为分位数。

Definition 5 (分位数) 设连续随机变量X的概率密度函数为f(X), 对于任意0 , 则满足条件

$$\int_{\alpha_p}^{\infty} f(x) = p$$

的 α_p 称为上侧p分位数。 满足条件

$$\int_{-\infty}^{\beta_p} f(x) = p$$

的 β_p 称为下侧p分位数。

在统计应用中,一些常用的分布通常预先计算好分位数表。需要使用时,直接通过概率查询对应分位数或者通过分位数查询概率,而不需要计算繁琐的积分。上侧分位数和下侧分位数具有如下对应关系。

$$\alpha_p = \beta_{1-p}, \beta_p = \alpha_{1-p}$$

本书采用上侧分位数作为查表计算方法。当p = 0.5时, 上侧分位数和下侧分位数相等, 此时称为中位数。



本节内容
连续等特征
均匀分布
指数分布





第 13 页 共 100 页

返 回

全 屏

4 均匀分布

Definition 6 (均匀分布) 如果随机变量X的概率密度为:

$$f(x) = \begin{cases} \frac{1}{b-a} & a < x < b \\ 0 & x \le a, or, x \ge b \end{cases}$$
 (4)

则称X在区间(a,b)内服从均匀分布,记为 $X \sim U(a,b)$,其分布函数为

$$F(x) = \begin{cases} 0 & x < a \\ \frac{x-a}{b-a} & a \le x < b \\ 1 & x \ge b \end{cases}$$
 (5)

数字特征:

$$E(X) = \int_{-\infty}^{+\infty} x f(x) dx = \int_{-\infty}^{+\infty} \frac{x}{b - a} dx = \frac{a + b}{2}$$

$$E(X^2) = \int_{-\infty}^{+\infty} \frac{x^2 f(x) dx}{x^2 f(x) dx} = = \int_{-\infty}^{+\infty} \frac{x^2}{b - a} dx$$

$$= \frac{b^3 - a^3}{3(b - a)} = \frac{a^2 + b^2 + ab}{3}$$

$$Var(X) = \frac{a^2 + b^2 + ab}{3} - \frac{a^2 + b^2 + 2ab}{4} = \frac{(b - a)^2}{12}$$



本节内容 连续随机变量 数字特征 均匀分布 指数分布 正态分布





第 14 页 共 100 页

返回

全 屏

均匀分布

Example 3 设电阻值R是一个随机变量,均匀分布在900-1100欧. 求R的 概率密度及R落在950-1050的概率.

$$f(r) = \frac{1}{1100 - 900}, 900 \le r \le 1100$$

则有

$$F(1050) - F(950) = \int_{950}^{1050} f(r)dr = 0.5$$

思考: 离散均匀分布?



本节内容连续为行机。





返 回

全 屏

Definition 7 如果随机变量X的概率密度为:

$$f(x) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}} & x > 0\\ 0 & x \le 0 \end{cases}$$
 (6)

或者

$$f(x) = \begin{cases} \lambda e^{-\lambda x} & x > 0\\ 0 & x \le 0 \end{cases} \tag{7}$$

则称X服从参数为 $\lambda(\lambda > 0)$ 的指数分布, 记为 $X \sim E(\lambda)$, 其分布函数为:

$$F(x) = \begin{cases} 1 - e^{-\frac{x}{\theta}} & x > 0\\ 0 & x \le 0 \end{cases} \tag{8}$$

或者

$$F(x) = \begin{cases} 1 - e^{-\lambda x} & x > 0\\ 0 & x \le 0 \end{cases} \tag{9}$$



本节内容 连续等特征 均匀分布 指数分布 正态分布






第 16 页 共 100 页

返 回

全 屏





本节内容 连续随机变字特征 均匀分布 指数分布 正态分布





第 17页 共 100页

返 回

全 屏

$$P\{X > s + t | X > s\} = P\{X > t\}$$

这一性质称为指数分布的<mark>无记忆性</mark>, 事实上可以证明指数分布是唯一具有上述性质的连续型分布.

证明:

$$\begin{split} P\{X>s+t|X>s\} &= \frac{P\{(X>s+t)\cap(X>s)\}}{P\{X>s\}} = \frac{P\{X>s+t\}}{P\{X>s\}} \\ &= \frac{P\{X>s+t\}}{P\{X>s\}} = \frac{1-E(s+t)\}}{1-E(s)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda(s)}} = e^{-\lambda t} = P\{X>t\} \end{split}$$







第 18 页 共 100 页

返 回

全 屏

指数分布数字特征

Theorem 3 设随机变量X指数分布, 即概率密度为

$$f(x) = \frac{1}{\theta} e^{-\frac{x}{\theta}}, x > 0$$

则
$$E(X) = \theta = \frac{1}{\lambda}, Var(X) = \theta^2 = \frac{1}{\lambda^2}.$$

证:

$$E(X) \int_{-\infty}^{\infty} x f(x) dx = \int_{0}^{\infty} x \frac{1}{\theta} e^{-\frac{x}{\theta}} dx$$

$$= -x e^{-\frac{x}{\theta}} \Big|_{0}^{\infty} + \int_{0}^{\infty} e^{-\frac{x}{\theta}} = \theta$$

$$E(X^{2}) \int_{-\infty}^{\infty} x^{2} f(x) dx = \int_{0}^{\infty} x^{2} \frac{1}{\theta} e^{-\frac{x}{\theta}} dx$$

$$= -x^{2} e^{-\frac{x}{\theta}} \Big|_{0}^{\infty} + \int_{0}^{\infty} 2x e^{-\frac{x}{\theta}} = 2\theta^{2}$$

$$Var(X) = E(X^{2}) - E(X)^{2} = \theta^{2}$$



本节内容。连续字特征。





第 19页共 100页

返 回

全 屏

泊松过程是一种重要的随机过程。泊松过程中,第k次随机事件与第k+1次随机事件出现的时间间隔服从指数分布。这是因为,第k次随机事件之后长度为t的时间段内,第k+1次随机事件出现的概率等于1减去这个时间段内没有随机事件出现的概率。而根据泊松过程的定义,长度为t的时间段内没有随机事件出现的概率等于 λt 的泊松分布概率

$$\underbrace{\frac{(\lambda t)^0}{0!}}_{e} e^{-(\lambda t)} = e^{-(\lambda t)}$$

Example 4 已知设备无故障运行10个小时, 求再无故障运行8小时的概率. 解:

$$P\{T \ge 18|T > 10\} = \frac{P\{T > 18\}}{P\{T > 10\}} = P\{T > 8\} = e^{-8t}$$



本节内容。
连续字句机证
均为分布





第 20 页 共 100 页

返回

全 屏



Example 5 电子元件的寿命X(年)服从参数为 $\lambda = 3$ 的指数分布:

- (1) 求该电子元件寿命超过2年的概率。
- (2) 已知该电子元件已使用了1.5年,求它还能使用两年的概率为多少?



本节内容。
连续字句机证
均为分布



第 21 页 共 100 页

返回

全 屏

Definition 8 如果随机变量X 的概率密度为:

$$\varphi(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

则称X 服从参数为 μ , σ^2 的正态分布,记为 $X \sim N(\mu, \sigma^2)$,其中参数 $\mu \in R, \sigma > 0$.

正态分布最早是棣莫弗在1718年著作的书籍的及1734年发表的一篇关于二项分布文章中提出的,当二项随机变量的位置参数n很大及形状参数为1/2时,则所推导出二项分布的近似分布函数就是正态分布。拉普拉斯在1812年发表的《分析概率论》中对棣莫弗的结论作了扩展到二项分布的位置参数为n及形状参数为p时。现在这一结论通常被称为棣莫佛一拉普拉斯定理。拉普拉斯在误差分析试验中使用了正态分布。勒让德于1805年引入最小二乘法这一重要方法;而高斯则宣称他早在1794年就使用了该方法,并通过假设误差服从正态分布给出了严格的证明。



本节内容。连续为机。



返回

全 屏

当 $\mu = 0, \sigma = 1, \pi X$ 服从标准正态分布, 记为 $X \sim N(0,1)$, 分布函数记为 $\Phi(x)$. 有

$$\Phi(-x) = 1 - \Phi(x)$$

练习:标准正态分布查表。

在自然现象和社会现象中, 大量随机变量都服从或近似服从正态分布. 如人的身体特征指标(身高、体重), 学习成绩, 产品的数量指标等等都服从正态分布. 许多较复杂的指标, 只要在受到的大量因素作用下每个因素的影响都不显著, 且因素相互独立, 也可认为近似服从正态分布. 又如二项分布、泊松分布在n很大时, 也以正态分布为极限分布. 因此, 可以说正态分布是最重要的分布.



本 节内容 连续对机变量 数字特征 均匀分布 指数分布 正态分布





全 屏

返 回

正态分布性质:

- \square 曲线关于 $x = \mu$ 对称.
- □ 固定 σ , 改变 μ , 曲线沿 O_x 轴平移;
- □ 固定 μ , 改变 σ , 由于最大值为 $\frac{1}{\sqrt{2\pi}\sigma}$. 曲线变得越尖, 因而X落在 μ 附近的概率越大.







本节内容等数字的机证。





第 24 页 共 100 页

返 回

全 屏

正态分布标准化:

Theorem 4 若 $X \sim N(\mu, \sigma^2)$, 则 $Z = \frac{X-\mu}{\sigma} \sim N(0, 1)$.

证明:

$$P\{Z \le x\} = P\{\frac{X - \mu}{\sigma} \le x\} = P\{X \le \mu + \sigma x\}$$
$$= \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^{\mu + \sigma x} e^{-\frac{(t - \mu)^2}{2\sigma^2}} dt$$

令 $y = \frac{t-u}{\sigma}$,则

$$P\{Z \le x\} = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{x} e^{-\frac{y^2}{2}} dy = \Phi(x)$$

所以 $Z = \frac{X-\mu}{\sigma} \sim N(0,1)$.







第 25 页 共 100 页

返 回

全 屏

正态分布数字特征

Theorem 5 $Z \sim N(0,1)$, 证明E(X) = 0, Var(X) = 1.

证明:

$$E(Z) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} t e^{-\frac{t^2}{2}} dt = 0$$

$$Var(Z) = E(Z^2) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} t^2 e^{-\frac{t^2}{2}} dt$$

$$= -\frac{1}{\sqrt{2\pi}} t e^{-\frac{t^2}{2}} \Big|_{-\infty}^{+\infty} + \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} e^{-\frac{t^2}{2}} dt = 1$$

对于任意
$$X \sim N(\mu, \sigma^2)$$
, $Z = \frac{X-\mu}{\sigma} \sim N(0, 1)$. 所以
$$E(X) = E(\mu + \sigma Z) = \mu$$

$$Var(X) = Var(\mu + \sigma Z) = \sigma^2 D(Z) = \sigma^2$$







第 26 页 共 100 页

返 回

全 屏

Example 6 一种电子元件的使用寿命 $X \sim \mathbb{N}(100, 15^2)$,某仪器上装有3个这种元件,三个元件损坏与否是相互独立的.求:使用的最初90小时内无一元件损坏的概率.





第 27页 共 100页

返回

全 屏

Example 7 一批钢材(线材)长度 $X \sim N(\mu, \sigma^2)$

- (1)若 $\mu = 100$, $\sigma = 2$, 求这批钢材长度小于97.8cm的概率;
- (2)若 $\mu = 100$, 要使这批钢材的长度至少有90%落在区间(97,103)内, 问 σ 至 多取何值?

解: (1)

$$P\{X < 97.8\} = \Phi(\frac{97.8 - 100}{2}) = 1 - \Phi(1.1) = 1 - 0.8643 = 0.1357$$

(2)

$$0.90 \le P\{97 < X < 103\} = \Phi(\frac{103 - 100}{\sigma}) - \Phi(\frac{97 - 100}{\sigma})$$

$$= 2\Phi(\frac{3}{\sigma}) - 1 \Rightarrow \Phi(\frac{3}{\sigma}) \ge 0.95 \Rightarrow \frac{3}{\sigma} \ge 1.645$$

所以 $\sigma \leq 1.8237$.



本节内容 连续 克机 数字特征 均匀分布 指数分布

正态分布





第 28 页 共 100 页

返回

全 屏

Example 8 将一温度调节器放置在存储着某种液体的容器内, 调节器定在d, 液体的温度X是一个随机变量, 且 $X \sim N(d, 0.5^2)$. (1)若d = 90, 求X < 89的概率; (2)若要求保持液体的温度至少为80的概率不低于0.99, 问d至少为80少?



本节内容
连续等特征
均匀分布
指数分布



第 29 页 共 100 页

返 回

全 屏

解: (1)

$$P\{X < 89\} = P\{\frac{X - 90}{0.5} < \frac{89 - 90}{0.5}\} = \Phi(\frac{89 - 90}{0.5})$$
$$= \Phi(-2) = 1 - \Phi(2) = 1 - 0.9772 = 0.228$$

(2)

$$0.99 \le P\{X \ge 80\} = P\{\frac{X - d}{0.5} \ge \frac{80 - d}{0.5}\}$$
$$= 1 - P\{\frac{X - d}{0.5} < \frac{80 - d}{0.5}\} = 1 - \Phi(\frac{80 - d}{0.5})$$
$$\Phi(\frac{80 - d}{0.5}) \le 1 - 0.99 = 1 - \Phi(2.327) = \Phi(-2.327)$$

即 $\frac{80-d}{0.5} \le -2.327$, d > 81.1635.



本节内容。

生实为切证。

少为分布。

我分布。





返 回

全 屏